

INFORME DE MEDICION Y REDUCCION DE LATENCIA
Asistente de emergencias | STT -> LLM -> TTS + RAG
4 de septiembre de 2026

RESUMEN EJECUTIVO

Configuracion seleccionada localmente

STT: Deepgram Nova-3/es
LLM: GPT-4.1-mini
TTS: Cartesia Sonic 3.6 (misma voz)
Endpointing: fijo, minimo 0.3 s, maximo 2.5 s
TTS preemptivo: activado, maximo 10 s
Prefetch RAG: desactivado

No se desplego a LiveKit Cloud. El rollback es inmediato con:
ENDPOINTING_MODE=dynamic PREEMPTIVE_TTS=false

METODO Y LIMITACIONES

- * Corridas manuales locales, con sesiones nuevas por escenario.
- * Se excluyen fillers de los p50 de respuestas utiles.
- * Se registran EOU, STT, TTFT LLM, TTFB TTS, RAG, E2E y saludo.
- * playback_latency es local al pipeline, no mide el viaje de red al usuario.
- * Cada corrida tiene entre 1 y 3 turnos utiles. Las conclusiones son direccionales; no reemplazan Agent Insights ni una validacion Cloud.

OPCIONES DE VOZ EVALUADAS

1) BASELINE DINAMICO - HEMORRAGIA

Muestras utiles: 3
p50 E2E: 2.535 s | p50 EOU: 676 ms | p50 RAG: 1.240 s
Referencia RAG. El turno RAG frio llego a 13.565 s E2E, dominado por un EOU de 4.501 s.

2) ENDPOINTING FIJO + TTS PREEMPTIVO - HEMORRAGIA

Muestras utiles: 3
p50 E2E: 2.155 s | p50 EOU: 632 ms | p50 RAG: 1.745 s
Estado: candidato. Mejoro la respuesta util aun cuando RAG vario.

3) ENDPOINTING FIJO SIN TTS PREEMPTIVO - HEMORRAGIA

Muestras utiles: 2, ambas con RAG
p50 E2E: 6.982 s | p50 EOU: 1.525 s | p50 RAG: 830 ms
Estado: DESCARTADO. Respuestas utiles lentas, mas loops y fillers.

4) DEEPGRAM FLUX + FIJO + PREEMPTIVO - HEMORRAGIA

Muestras utiles: 3
p50 E2E: 2.744 s | p50 EOU: ~0 ms* | p50 RAG: 1.637 s
Estado: DESCARTADO. E2E 27.4% peor que Nova-3 comparable.
* Flux emitio transcription_delay y duracion STT en 0; no se toma como transcripcion instantanea sino como metrica no disponible.

5) NOVA-3 + PREFETCH RAG - HEMORRAGIA

Muestras utiles: 3
p50 E2E: 5.713 s | p50 EOU: 2.501 s | p50 RAG: 863 ms
Estado: DESCARTADO. El prefetch coincidente funciono, pero EOU llego repetidamente al maximo y la experiencia percibida fue peor.

6) VALIDACION FINAL - HEMORRAGIA

Muestras utiles: 3
p50 E2E: 1.731 s | p50 EOU: 819 ms | p50 RAG: 921 ms
Estado: MEJOR CORRIDA COMPARABLE.

7) VALIDACION FINAL - INCONSCIENTE / NO RESPIRA

Muestras utiles: 3

p50 E2E: 5.148 s | p50 EOU: 613 ms | p50 RAG: 858 ms

Estado: valido en flujo critico. No hay baseline critico identico, por lo que no se informa una mejora porcentual.

COMPARACION: BASELINE RAG VS VALIDACION FINAL (HEMORRAGIA)

	Baseline	Final	Diferencia
p50 E2E global	2.535 s	1.731 s	-804 ms (-31.7%)
p50 E2E sin RAG	2.043 s	1.352 s	-691 ms
Turno RAG frio E2E	13.565 s	7.511 s	-6.054 s
RAG total	1.240 s	921 ms	-319 ms
TTFT LLM	1.090 s	939 ms	-150 ms
TTFB TTS	288 ms	273 ms	-15 ms

PREFETCH RAG: ANALISIS

El primer prefetch de hemorragia fue reutilizado correctamente: 929 ms frente a 1.745 s del RAG de referencia. Sin embargo, esa ganancia no compenso el EOU de aproximadamente 2.5 s. El p50 E2E empeoro de 2.155 s a 5.713 s. Ante una consulta posterior de otra categoria (no respira), el sistema no reutilizo el contexto de hemorragia: comportamiento seguro, pero de beneficio limitado. Por eso queda apagado.

EVALUACION DE LLM POR TEXTO

Modelo	Resultado de gates	Decision
GPT-4.1-mini	20/23 asertos; falla casco en esa corrida	Control
GPT-4.1-nano	20/23; omite RAG/RCP en corrida critica	DESCARTADO
GPT-4o-mini	18/23; falla casco y contencion	DESCARTADO
GPT-5-mini	Timeout/retry en primera generacion	DESCARTADO
GPT-5.4-mini	3/4 en casco; sin razon cervical	DESCARTADO
GPT-5.4-nano	1/3 escenarios completos; critico 10/11	DESCARTADO

El LLM no se cambio: para la optimizacion de latencia se conserva GPT-4.1-mini como control. Un modelo mas rapido no es aceptable si degrada instrucciones medicas, tool calling o grounding.

GATES DE SEGURIDAD Y COMPORTAMIENTO

- * En la validacion critica, "inconsciente" no disparo RAG de RCP. La busqueda se activo despues de confirmar "no respira".
- * La interrupcion intencional cancelo el LLM en curso sin iniciar TTS. No se observo audio iniciado y cortado.
- * Flux se descarto por latencia y por no permitir validar adecuadamente las metricas de transcripcion/terminos criticos.
- * Suite tecnica: 35 tests aprobados.

RECOMENDACION

Adoptar localmente el perfil seleccionado:

```
ENDPOINTING_MODE=fixed
ENDPOINTING_MIN_DELAY=0.3
ENDPOINTING_MAX_DELAY=2.5
PREEMPTIVE_TTS=true
PREEMPTIVE_MAX_SPEECH_DURATION=10
RAG_PREFETCH_CRITICAL=false
```

Antes de desplegar: validar en LiveKit Cloud los escenarios hemorragia y critico, contrastar las metricas del agente con Agent Insights y revisar grabaciones para confirmar la latencia percibida.

FUENTES

Eventos crudos: `metricas/resultados/latencia_raw/*.jsonl`

Reportes: `metricas/resultados/latencia_*.json` y `latencia_*.md`